

Álgebra Lineal Computacional

Resolución del segundo parcial, 1C 2025 – @valnrms

Fecha de compilación: 14/07/2025.


Ejercicio 1

En la final del Mundial de Clubes de la FIFA 2025, el Inter de Miami y Benfica definen el título mediante tiros desde el punto penal. Los jugadores de cada uno de los equipos deben decidir si patean a la izquierda, al medio o a la derecha.

Basado en estudios recientes, se sabe que si un jugador j_1 eligió patear a la derecha, el siguiente en la tanda, j_2 , elige patear a la derecha un 20% de las veces, al medio un 30% y a la izquierda un 50%. La situación si j_1 elige patear a la izquierda es análoga, es decir, j_2 patea a la izquierda el 20% de las veces, al medio el 30% y a la derecha el 50%. Finalmente, si j_1 le parece muy obvio hacer lo mismo, así que patea al medio el 10% de las veces, y patea a los lados con igual probabilidad cada uno.

- Modelar el proceso mediante una matriz de Markov P .
- Si Lionel Messi, el primer pateador, disparó al lado derecho, ¿cuáles son las probabilidades de que Fideo Di María, el cuarto pateador, patee a cada lugar?
- Si asumimos que la tanda de penales se hace larguísima y la gente comienza a irse del estadio del aburrimiento, decidir si existe un estado límite para las probabilidades de patear a cada lugar de cada jugador, y calcular, si existe, P^∞ .

Inciso (a)



Este diagrama de transición de estados se puede representar con la siguiente **matriz de Markov**:

$$P = \begin{pmatrix} 0.2 & 0.45 & 0.5 \\ 0.3 & 0.1 & 0.3 \\ 0.5 & 0.45 & 0.2 \end{pmatrix}$$

P_{ij} es la probabilidad de pasar del estado j al estado i .

Notar que es una matriz estocástica¹, pues la suma de sus columnas es 1 y todos sus elementos son ≥ 0 .

La columna y fila 1 se relaciona con el estado **Izq.**, la columna y fila 2 con el estado **Med.** y la columna y fila 3 con el estado **Der.**

Inciso (b)

Interpretemos primero el enunciado.

Sabemos que Messi arrancó pateando a la derecha, por lo que podemos tomar $v^{(1)2} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$. Queremos encontrar $v^{(4)}$, que corresponde a las probabilidades de que Fideo Di María patee a la izquierda, al medio o a la derecha en el cuarto tiro.

¹También llamada de Markov.

²Generalmente tomamos $v^{(0)}$ como primer vector, tomo $v^{(1)}$ porque creo que marea menos, pues eso nos permite tomar que el cuarto jugador es $v^{(4)}$ en lugar de $v^{(3)}$.

Tenemos dos formas, una es calcular $P^3 = PPP$ y luego hacemos esta cuenta $v^{(4)} = P^3 v^{(1)}$.

La otra forma es ver si P es diagonalizable, luego, si lo es, sabemos que $P^n = CD^nC^{-1}$.

Uno podría tentarse en ir por la segunda opción, pero es importante notar que va a ser necesario calcular los autovectores de P , por lo que puede ser medio engorroso.

Hagámoslo de manera obrera, no son tantas cuentas.

$$\begin{aligned}
 P^3 &= PPP \\
 &= \begin{pmatrix} 0.2 & 0.45 & 0.5 \\ 0.3 & 0.1 & 0.3 \\ 0.5 & 0.45 & 0.2 \end{pmatrix} \begin{pmatrix} 0.2 & 0.45 & 0.5 \\ 0.3 & 0.1 & 0.3 \\ 0.5 & 0.45 & 0.2 \end{pmatrix} \begin{pmatrix} 0.2 & 0.45 & 0.5 \\ 0.3 & 0.1 & 0.3 \\ 0.5 & 0.45 & 0.2 \end{pmatrix} \\
 &= \begin{pmatrix} 0.2 & 0.45 & 0.5 \\ 0.3 & 0.1 & 0.3 \\ 0.5 & 0.45 & 0.2 \end{pmatrix} \begin{pmatrix} 0.425 & 0.36 & 0.335 \\ 0.24 & 0.28 & 0.24 \\ 0.335 & 0.36 & 0.425 \end{pmatrix} \\
 &= \begin{pmatrix} 0.3605 & 0.378 & 0.3875 \\ 0.252 & 0.244 & 0.252 \\ 0.3875 & 0.378 & 0.3605 \end{pmatrix}
 \end{aligned}$$

Luego,

$$\begin{aligned}
 v^{(4)} &= P^3 v^{(1)} \\
 &= \begin{pmatrix} 0.3605 & 0.378 & 0.3875 \\ 0.252 & 0.244 & 0.252 \\ 0.3875 & 0.378 & 0.3605 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \\
 &= \begin{pmatrix} 0.3875 \\ 0.252 \\ 0.3605 \end{pmatrix}
 \end{aligned}$$

Es decir, el Fideo Di María pateará a la izquierda con probabilidad 38.75%, al medio con probabilidad 25.2% y a la derecha con probabilidad 36.05%.

Es más barato computacionalmente hacer $v^{(2)} = Pv^{(1)}$, luego $v^{(3)} = Pv^{(2)}$, y finalmente $v^{(4)} = Pv^{(3)}$, pues es más barato hacer mutiplicaciones entre matrices y vectores que hacer multiplicaciones entre matrices.

Inciso (c)

Nos piden decidir si existe un estado límite, $v^{(\infty)}$, alcanzable a partir de cualquier estado inicial. Y, si existe, calcular P^∞ .

Sabemos que si existe P^∞ , entonces va a existir un estado límite, $v^{(\infty)}$, para cualquier estado inicial, $v^{(1)}$, pues bastaría con hacer $v^{(\infty)} = P^\infty v^{(1)}$.

Sabemos que si P es diagonalizable, y el único autovalor λ tal que $|\lambda| = 1$ es $\lambda = 1$, entonces existe P^∞ y, por lo tanto, un estado límite alcanzable a partir de cualquier estado inicial.

Para saber si P es diagonalizable, calculamos sus autovalores.

$$\lambda \text{ es autovalor de } P \iff \det(P - \lambda I) = 0$$

Calculemos el determinante de $P - \lambda I$:

$$\det(\mathbf{P} - \lambda \mathbf{I}) = \begin{vmatrix} 0.2 - \lambda & 0.45 & 0.5 \\ 0.3 & 0.1 - \lambda & 0.3 \\ 0.5 & 0.45 & 0.2 - \lambda \end{vmatrix} \rightarrow \begin{vmatrix} + & - & + \\ - & + & - \\ + & - & + \end{vmatrix}$$

$$=^3(0.2 - \lambda) \begin{vmatrix} 0.1 - \lambda & 0.3 \\ 0.45 & 0.2 - \lambda \end{vmatrix} - 0.45 \begin{vmatrix} 0.3 & 0.3 \\ 0.5 & 0.2 - \lambda \end{vmatrix} + 0.5 \begin{vmatrix} 0.3 & 0.1 - \lambda \\ 0.5 & 0.45 \end{vmatrix}$$

Desarrollemos primero cada menor:

$$\begin{vmatrix} 0.1 - \lambda & 0.3 \\ 0.45 & 0.2 - \lambda \end{vmatrix} = (0.1 - \lambda) \cdot (0.2 - \lambda) - 0.3 \cdot 0.45$$

$$= (0.02 - 0.1\lambda - 0.2\lambda + \lambda^2) - 0.135$$

$$= \lambda^2 - 0.3\lambda - 0.115$$

$$\begin{vmatrix} 0.3 & 0.3 \\ 0.5 & 0.2 - \lambda \end{vmatrix} = 0.3 \cdot (0.2 - \lambda) - 0.3 \cdot 0.5$$

$$= (0.06 - 0.3\lambda) - 0.15$$

$$= -0.3\lambda - 0.09$$

$$\begin{vmatrix} 0.3 & 0.1 - \lambda \\ 0.5 & 0.45 \end{vmatrix} = 0.3 \cdot 0.45 - (0.1 - \lambda) \cdot 0.5$$

$$= 0.135 + (-0.05 + 0.5\lambda)$$

$$= 0.5\lambda + 0.085$$

Luego,

$$\det(\mathbf{P} - \lambda \mathbf{I}) = |\cdot| = (0.2 - \lambda) \begin{vmatrix} 0.1 - \lambda & 0.3 \\ 0.45 & 0.2 - \lambda \end{vmatrix} - 0.45 \begin{vmatrix} 0.3 & 0.3 \\ 0.5 & 0.2 - \lambda \end{vmatrix} + 0.5 \begin{vmatrix} 0.3 & 0.1 - \lambda \\ 0.5 & 0.45 \end{vmatrix}$$

$$= (0.2 - \lambda)(\lambda^2 - 0.3\lambda - 0.115) - 0.45(-0.3\lambda - 0.09) + 0.5(0.5\lambda + 0.085)$$

$$= ((0.2\lambda^2 - 0.06\lambda - 0.023) - \lambda^3 + 0.3\lambda^2 + 0.115\lambda) + (0.135\lambda + 0.0405) + (0.25\lambda + 0.0425)$$

$$= (-\lambda^3 + 0.5\lambda^2 + 0.055\lambda - 0.023) + (0.135\lambda + 0.0405) + (0.25\lambda + 0.0425)$$

$$= -\lambda^3 + 0.5\lambda^2 + 0.44\lambda + 0.06$$

Ahora, resolvemos la ecuación $-\lambda^3 + 0.5\lambda^2 + 0.44\lambda + 0.06 = 0$ para encontrar los autovalores.

Sabemos usar la fórmula de Bhaskara⁴, $\lambda_{\pm} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$, para encontrar raíces de polinomios de grado 2, pero este es de grado 3.

Sin embargo, conocemos una raíz de este polinomio. Las raíces de este polinomio representan los autovalores de la matriz $\mathbf{P}$, y sabemos 1 es autovalor de toda matriz de Markov, pues, en toda matriz de Markov siempre existe al menos un estado de equilibrio.

Por si no me creen, revisen que $\det(\mathbf{P} - \mathbf{I}) = -1 + 0.5 + 0.44 + 0.06 = 0$.

Por lo que podemos aplicar Ruffini (o realizar una división de polinomios) para bajar el grado del mismo.

³Utilizando el método de cofactores, desarrollo por fila 1.

⁴También llamada resolvente.

$$\begin{array}{c|cccc}
 & -1 & 0.5 & 0.44 & 0.06 \\
 1 & -1 & -0.5 & -0.06 & 0 \\
 \hline
 & -1 & -0.5 & -0.06 & 0
 \end{array}
 \qquad
 \begin{array}{cccc|c}
 -\lambda^3 & 0.5\lambda^2 & 0.44\lambda & 0.06 & \lambda - 1 \\
 -\lambda^3 & \lambda^2 & & & -\lambda^2 - 0.5\lambda - 0.06 \\
 \hline
 & -0.5\lambda^2 & 0.44\lambda & 0.06 & \\
 & -0.5\lambda^2 & 0.5\lambda & & \\
 \hline
 & & -0.06\lambda & 0.06 & \\
 & & -0.06\lambda & 0.06 & \\
 \hline
 & & & & 0
 \end{array}$$

Utilizando tanto el método de Ruffini como la división de polinomios, obtenemos que el polinomio se puede expresar como:

$$(\lambda - 1) \cdot (-\lambda^2 - 0.5\lambda - 0.06)$$

Y ahora sí podemos utilizar la fórmula de Bhaskara, $\lambda_{\pm} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$, para encontrar las otras dos raíces:

Sean $a = -1$, $b = -0.5$ y $c = -0.06$.

$$\begin{aligned}
 \lambda_+ &= \frac{-(-0.5) + \sqrt{(-0.5)^2 - 4(-1)(-0.06)}}{2(-1)} & \lambda_- &= \frac{-(-0.5) - \sqrt{(-0.5)^2 - 4(-1)(-0.06)}}{2(-1)} \\
 &= \frac{0.5 + \sqrt{0.25 - 0.24}}{-2} & &= \frac{0.5 + \sqrt{0.25 + 0.24}}{-2} \\
 &= \frac{0.5 + \sqrt{0.01}}{-2} = \frac{0.5 + 0.1}{-2} = \frac{0.6}{-2} = -0.3 & &= \frac{0.5 - \sqrt{0.01}}{-2} = \frac{0.5 - 0.1}{-2} = \frac{0.4}{-2} = -0.2
 \end{aligned}$$

Finalmente, $-\lambda^3 + 0.5\lambda^2 + 0.44\lambda + 0.06 = (\lambda - 1)(\lambda + 0.3)(\lambda + 0.2)$, por lo que los autovalores de $\mathbf{P}$ son:

$$\lambda_1 = 1 \qquad \lambda_2 = -0.3 \qquad \lambda_3 = -0.2$$

Como todos los autovalores son $\neq 1$, $\mathbf{P}$ es diagonalizable. Además, el único autovalor λ tal que $|\lambda| = 1$ es 1. Esto implica que existe $\mathbf{P}^\infty$ y $v^{(\infty)}$ alcanzable a partir de cualquier estado inicial.

Post hacer todas las cuentas, dos amigos: Bacher y Guido, me recordaron dos propiedades.

- * $\text{tr}(\mathbf{P}) = \lambda_1 + \lambda_2 + \lambda_3 = 1 + \lambda_2 + \lambda_3$
- * $\det(\mathbf{P}) = \lambda_1 \cdot \lambda_2 \cdot \lambda_3 = \lambda_2 \cdot \lambda_3$

Por lo que uno tiene ahora dos ecuaciones, con dos incógnitas: λ_2 y λ_3 .

De ahí obtenemos que

$$\begin{aligned}
 * \quad \underbrace{\lambda_1}_{1} + \lambda_2 + \lambda_3 &= \underbrace{\text{tr}(\mathbf{P})}_{0.5} \iff \lambda_2 = -0.5 - \lambda_3 \\
 * \quad \lambda_2 \lambda_3 &= \overbrace{\det(\mathbf{P})}^{0.06} \iff_{\lambda_{1,2} \neq 0 \text{ pues } \det(\mathbf{P}) \neq 0} \lambda_2 = \frac{0.06}{\lambda_3}
 \end{aligned}$$

Y de acá se puede despejar λ_3 y luego λ_2 :

- * $\frac{0.06}{\lambda_3} = -0.5 - \lambda_3 \iff \lambda_3^2 + 0.5\lambda_3 + 0.06 = 0 \iff \lambda_3 = -0.3 \vee \lambda_3 = -0.2$
- * **Enchufando cualquiera de los dos λ_3 obtenidos en cualquiera de las dos ecuaciones anteriores, obtenemos que $\lambda_2 = -0.2$ o $\lambda_2 = -0.3$ respectivamente.**

Luego nos quedan los siguientes autovalores:

$$\lambda_1 = 1 \qquad \lambda_2 = -0.3 \qquad \lambda_3 = -0.2 \qquad \text{ó} \qquad \lambda_1 = 1 \qquad \lambda_2 = -0.2 \qquad \lambda_3 = -0.3$$

Ahora, queremos calcular $\mathbf{P}^\infty$.

Por la teórica, sabemos que si $\mathbf{P}$ es diagonalizable, el único autovalor λ tal que $|\lambda| = 1$ es $\lambda = 1$, y $\text{mg}_{\mathbf{P}}(1) = \text{ma}_{\mathbf{P}}(1) = 1$, entonces:



$$P^\infty = \begin{pmatrix} \vdots & \vdots & \vdots \\ w & w & w \\ \vdots & \vdots & \vdots \end{pmatrix}, \quad \text{donde } w \text{ es el autovector normalizado con norma 1 asociado a } \lambda = 1$$

Y como $\text{ma}_P(1)$ sabemos que es igual a 1 –matriz de 3×3 con todos autovalores distintos–, sabemos entonces que $\text{mg}_P(1) = 1$.

Luego, busquemos el autoespacio asociado a $\lambda = 1$:

$$\begin{aligned} (x, y, z) \text{ es autovector de } P \text{ asociado a } \lambda = 1 &\Leftrightarrow P \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} x \\ y \\ z \end{pmatrix} \Leftrightarrow (P - I) \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} 0.2 - 1 & 0.45 & 0.5 \\ 0.3 & 0.1 - 1 & 0.3 \\ 0.5 & 0.45 & 0.2 - 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} -0.8 & 0.45 & 0.5 \\ 0.3 & -0.9 & 0.3 \\ 0.5 & 0.45 & -0.8 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \end{aligned}$$

Como soy muy vago para ponerme a triangular la matriz, planteo directamente el sistema de ecuaciones asociado:

$$\begin{cases} -0.8x + 0.45y + 0.5z = 0 & (\text{ec. I}) \\ 0.3x - 0.90y + 0.3z = 0 & (\text{ec. II}) \\ 0.5x + 0.45y - 0.8z = 0 & (\text{ec. III}) \end{cases} \Leftrightarrow \begin{cases} 1.3x - 1.3z = 0 \Leftrightarrow x = z & (\text{ec. IV, de hacer III} - \text{I}) \\ -0.90y + 0.6z = 0 \Leftrightarrow y = \frac{2}{3}z & (\text{ec. V, de enchufar IV en II}) \end{cases}$$

Por lo que el autoespacio asociado a $\lambda = 1$ es:

$$S_1 = \left\{ \begin{pmatrix} x \\ y \\ z \end{pmatrix} \in \mathbb{R}^3 : x = z \wedge y = \frac{2}{3}z \right\} = \left\langle \begin{pmatrix} 1 \\ \frac{2}{3} \\ 1 \end{pmatrix} \right\rangle$$

Luego, el autovector normalizado con norma 1 asociado a $\lambda = 1$ es:

$$w = \frac{\begin{pmatrix} 1 \\ \frac{2}{3} \\ 1 \end{pmatrix}}{\left\| \begin{pmatrix} 1 \\ \frac{2}{3} \\ 1 \end{pmatrix} \right\|_1} = \frac{\begin{pmatrix} 1 \\ \frac{2}{3} \\ 1 \end{pmatrix}}{|1| + |\frac{2}{3}| + |1|} = \frac{\begin{pmatrix} 1 \\ \frac{2}{3} \\ 1 \end{pmatrix}}{\frac{8}{3}} = \frac{3}{8} \begin{pmatrix} 1 \\ \frac{2}{3} \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{3}{8} \\ \frac{1}{4} \\ \frac{3}{8} \end{pmatrix}$$

Finalmente,

$$P^\infty = \begin{pmatrix} \frac{3}{8} & \frac{3}{8} & \frac{3}{8} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{3}{8} & \frac{3}{8} & \frac{3}{8} \end{pmatrix}$$

Ejercicio 2

x	-2	0	1	5
y	1	-13	12	4
z	27	-29	-12	26

Dada la siguiente tabla de datos:

- Hallar la función de la forma $z = ax + by + c$ que mejor aproxima en el sentido de cuadrados mínimos a los datos.
- Hallar la función de la forma $z = y + \frac{3}{ax+b}$ que mejor aproxima en el sentido de cuadrados mínimos a los datos.
- Determinar, a partir del error cometido, cuál de los modelos se ajusta más a los datos.

Inciso (a)

Nos dan una tabla de valores con 4 observaciones de tres variables: x , y y z . Nos piden encontrar la función

$$z = ax + by + c$$

que mejor aproxime esos datos en el sentido de cuadrados mínimos. Como nos piden aproximar por cuadrados mínimos, es razonable asumir que el sistema dado por los valores de la tabla no tiene solución, pues, si fuese este el caso, la función que mejor aproxima sería la que obtenemos despejando las incógnitas, a , b , c , del sistema compatible.

Recapitulando, tenemos un sistema incompatible, de manera tal que

$$\begin{pmatrix} 1 & y_1 & x_1 \\ 1 & y_2 & x_2 \\ 1 & y_3 & x_3 \\ 1 & y_4 & x_4 \end{pmatrix} \begin{pmatrix} c \\ b \\ a \end{pmatrix} = \begin{pmatrix} z_1 \\ z_2 \\ z_3 \\ z_4 \end{pmatrix} \iff z_i = ax_i + by_i + c$$

no tiene solución, y queremos encontrar *la mejor solución* posible, llamémosla $\hat{x} = \begin{pmatrix} \hat{c} \\ \hat{b} \\ \hat{a} \end{pmatrix}$, usando cuadrados mínimos. Debemos primer definir qué quiere decir *la mejor solución*.

Definimos a $\hat{x}$ como $\arg \min_{x \in \mathbb{R}^3} \{\|Ax - z\|_2^2\}$, es decir, como no podemos hacer que esa resta sea 0, queremos aproximarnos lo más posible.

Esto mismo se puede ver de otra forma (que es lo mismo), si pensamos a la función que buscamos como $f_{(a)}(x, y) = ax + by + c$, entonces queremos que la suma de la diferencia entre z_i y $f_{(a)}(x_i, y_i)$ (al cuadrado)⁵ sea lo más pequeña posible, para todos los puntos (x_i, y_i, z_i) que nos dan.

$$\sum_{i=1}^4 (z_i - f_{(a)}(x_i, y_i))^2 = \sum_{i=1}^4 (z_i - (ax_i + by_i + c))^2$$

Se suele definir $r_i = z_i - f_{(a)}(x_i, y_i)$ como el residuo de la aproximación. Luego, se busca minimizar la suma de los cuadrados de los residuos, $\sum_{i=1}^4 r_i^2$.

Bueno, mucha charla y poca cuenta. Definamos nuestra A , $\hat{x}$ y z .

$$A = \begin{pmatrix} 1 & y_1 & x_1 \\ 1 & y_2 & x_2 \\ 1 & y_3 & x_3 \\ 1 & y_4 & x_4 \end{pmatrix} = \begin{pmatrix} 1 & 1 & -2 \\ 1 & -13 & 0 \\ 1 & 12 & 1 \\ 1 & 4 & 5 \end{pmatrix} \quad \hat{x} = \begin{pmatrix} \hat{c} \\ \hat{b} \\ \hat{a} \end{pmatrix} \quad z = \begin{pmatrix} z_1 \\ z_2 \\ z_3 \\ z_4 \end{pmatrix} = \begin{pmatrix} 27 \\ -29 \\ -12 \\ 26 \end{pmatrix}$$

Ahora, para encontrar $\hat{x}$, debemos resolver el sistema $A^T A \hat{x} = A^T z$, que es el que mejor aproxima a z en el sentido de cuadrados mínimos.⁶

⁵Pedimos al cuadrado para hacernos más fácil las cuentas.

⁶Esto es un resultado de la teoría.



$$A^T A = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & -13 & 12 & 4 \\ -2 & 0 & 1 & 5 \end{pmatrix} \begin{pmatrix} 1 & 1 & -2 \\ 1 & -13 & 0 \\ 1 & 12 & 1 \\ 1 & 4 & 5 \end{pmatrix} = \begin{pmatrix} 4 & 4 & 4 \\ 4 & 330 & 30 \\ 4 & 30 & 30 \end{pmatrix} \quad A^T z = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & -13 & 12 & 4 \\ -2 & 0 & 1 & 5 \end{pmatrix} \begin{pmatrix} 27 \\ -29 \\ -12 \\ 26 \end{pmatrix} = \begin{pmatrix} 12 \\ 364 \\ 64 \end{pmatrix}$$

Ahora hay que resolver el sistema

$$\begin{pmatrix} 4 & 4 & 4 & | & 12 \\ 4 & 330 & 30 & | & 364 \\ 4 & 30 & 30 & | & 64 \end{pmatrix} \xrightarrow{\substack{F_2 \leftarrow F_2 - F_1 \\ F_3 \leftarrow F_3 - F_1}} \begin{pmatrix} 4 & 4 & 4 & | & 12 \\ 0 & 326 & 26 & | & 352 \\ 0 & 26 & 26 & | & 52 \end{pmatrix} \xrightarrow{F_3 \leftarrow \frac{326}{26} F_3 - F_2} \begin{pmatrix} 4 & 4 & 4 & | & 12 \\ 0 & 326 & 26 & | & 352 \\ 0 & 0 & 300 & | & 300 \end{pmatrix} \xrightarrow{F_3 \leftarrow \frac{1}{300} F_3} \begin{pmatrix} 4 & 4 & 4 & | & 12 \\ 0 & 326 & 26 & | & 352 \\ 0 & 0 & 1 & | & 1 \end{pmatrix}$$

$$\xrightarrow{F_2 \leftarrow F_2 - 26 F_3} \begin{pmatrix} 4 & 4 & 4 & | & 12 \\ 0 & 326 & 0 & | & 326 \\ 0 & 0 & 1 & | & 1 \end{pmatrix} \xrightarrow{\substack{F_1 \leftarrow \frac{1}{4} F_1 \\ F_2 \leftarrow \frac{1}{326} F_2}} \begin{pmatrix} 1 & 1 & 1 & | & 3 \\ 0 & 1 & 0 & | & 1 \\ 0 & 0 & 1 & | & 1 \end{pmatrix} \xrightarrow{F_1 \leftarrow F_1 - F_3} \begin{pmatrix} 1 & 1 & 0 & | & 2 \\ 0 & 1 & 0 & | & 1 \\ 0 & 0 & 1 & | & 1 \end{pmatrix} \xrightarrow{F_1 \leftarrow F_1 - F_2} \begin{pmatrix} 1 & 0 & 0 & | & 1 \\ 0 & 1 & 0 & | & 1 \\ 0 & 0 & 1 & | & 1 \end{pmatrix}$$

Es decir, tenemos que,

$$\begin{cases} \hat{c} = 1 \\ \hat{b} = 1 \\ \hat{a} = 1 \end{cases}$$

Luego, la función que mejor aproxima los datos en el sentido de cuadrados mínimos es

$$f_{(a)}(x, y) = x + y + 1$$

Inciso (b)

Bien, este es similar al anterior pero tiene un *catch*. Para resolver por cuadrados mínimos debemos poder expresar el sistema como $Ax = z$. Esto no tiene pinta así a simple vista de que se pueda hacer tan sencillamente como el inciso anterior.

Va a ser necesario **linealizar** el sistema, es decir, transformar las variables x y y en nuevas variables que nos permitan expresar el sistema como una matriz de la forma $Ax = z$.

$$z = y + \frac{3}{ax + b} \Leftrightarrow (z - y)(ax + b) = 3 \Leftrightarrow ax + b = \frac{3}{z - y}$$

Si definimos $\Phi_i = \frac{3}{z_i - y_i}$, entonces nos queda $ax + b = \Phi$. Esto es un poco más amigable para poder expresar el sistema como ecuaciones lineales, pues:

$$\begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{pmatrix} \begin{pmatrix} b \\ a \end{pmatrix} = \begin{pmatrix} \Phi_1 \\ \Phi_2 \\ \Phi_3 \\ \Phi_4 \end{pmatrix} \Leftrightarrow \Phi_i = ax_i + b$$

Veamos entonces cómo quedaría la nueva tablita.

x	-2	0	1	5
Φ	$\frac{3}{26}$	$-\frac{3}{16}$	$-\frac{3}{24}$	$\frac{3}{22}$

Tenemos que plantear A , $\hat{x}$ y z .

$$A = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{pmatrix} = \begin{pmatrix} 1 & -2 \\ 1 & 0 \\ 1 & 1 \\ 1 & 5 \end{pmatrix} \quad \hat{x} = \begin{pmatrix} \hat{b} \\ \hat{a} \end{pmatrix} \quad z = \begin{pmatrix} \Phi_1 \\ \Phi_2 \\ \Phi_3 \\ \Phi_4 \end{pmatrix} = \begin{pmatrix} \frac{3}{26} \\ -\frac{3}{16} \\ -\frac{3}{24} \\ \frac{3}{22} \end{pmatrix}$$

Igual que antes, nos toca resolver el sistema $A^T A \hat{x} = A^T z$.

$$A^T A = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -2 & 0 & 1 & 5 \end{pmatrix} \begin{pmatrix} 1 & -2 \\ 1 & 0 \\ 1 & 1 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 4 & 4 \\ 4 & 30 \end{pmatrix} \quad A^T z = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -2 & 0 & 1 & 5 \end{pmatrix} \begin{pmatrix} \frac{3}{26} \\ -\frac{3}{16} \\ -\frac{3}{24} \\ \frac{3}{22} \end{pmatrix} = \begin{pmatrix} -\frac{139}{2288} \\ \frac{373}{1144} \end{pmatrix}$$

Ahora, resolvemos el sistema

$$\left(\begin{array}{cc|c} 4 & 4 & -\frac{139}{2288} \\ 4 & 30 & \frac{373}{1144} \end{array} \right) \xrightarrow{F_2 \leftarrow F_2 - F_1} \left(\begin{array}{cc|c} 4 & 4 & -\frac{139}{2288} \\ 0 & 26 & \frac{885}{2288} \end{array} \right) \xrightarrow{F_1 \leftarrow \frac{1}{4} F_1, F_2 \leftarrow \frac{1}{26} F_2} \left(\begin{array}{cc|c} 1 & 1 & -\frac{139}{9152} \\ 0 & 1 & \frac{885}{59488} \end{array} \right) \xrightarrow{F_1 \leftarrow F_1 - F_2} \left(\begin{array}{cc|c} 1 & 0 & -\frac{3577}{118976} \\ 0 & 1 & \frac{885}{59488} \end{array} \right)$$

Es decir, tenemos que,

$$\begin{cases} \hat{b} = -\frac{3577}{118976} \\ \hat{a} = \frac{885}{59488} \end{cases}$$

Luego, la función que mejor aproxima los datos en el sentido de cuadrados mínimos es

$$f_{(b)}(x, y) = y + \frac{3}{\frac{885}{59488}x - \frac{3577}{118976}}$$

Inciso (c)

Tenemos dos funciones, $f_{(a)}(x, y)$ y $f_{(b)}(x, y)$, son las que mejor aproximan los datos en el sentido de cuadrados mínimos. Nos piden determinar cuál de las dos es mejor, para ello queremos comparar los residuos de cada una.

Podemos usar el resultado de la $\sum$ que mencionamos antes. Para cada función, calculamos la suma de los cuadrados de los residuos, $\sum_{i=1}^4 r_i^2$, donde $r_i = z_i - f_{(a)}(x_i, y_i)$ o $r_i = z_i - f_{(b)}(x_i, y_i)$.

$$\begin{aligned} \sum_{i=1}^4 r_{(a)i}^2 &= \sum_{i=1}^4 (z_i - f_{(a)}(x_i, y_i))^2 = \\ &= (27 - ((-2) + 1 + 1))^2 + \\ &+ (-29 - (0 + (-13) + 1))^2 + \\ &+ (-12 - (1 + 12 + 1))^2 + \\ &+ (26 - (5 + 4 + 1))^2 \\ \sum_{i=1}^4 r_{(b)i}^2 &= \sum_{i=1}^4 \left(z_i - f_{(b)}(x_i, y_i) \right)^2 = \\ &= \left(27 - \left(1 + \frac{3}{\frac{885}{59488}(-2) - \frac{3577}{118976}} \right) \right)^2 + \\ &+ \left(-29 - \left(-13 + \frac{3}{\frac{885}{59488}0 - \frac{3577}{118976}} \right) \right)^2 + \\ &+ \left(-12 - \left(12 + \frac{3}{\frac{885}{59488}1 - \frac{3577}{118976}} \right) \right)^2 + \\ &+ \left(26 - \left(4 + \frac{3}{\frac{885}{59488}5 - \frac{3577}{118976}} \right) \right)^2 \end{aligned}$$

No pienso resolver esas cuentas, pero, es “fácil”⁷ notar que el error de $f_{(b)}(x, y)$ es más grande que el de $f_{(a)}(x, y)$. Si prestamos atención a la sumatoria de $f_{(b)}$ podemos notar que tenemos una fracción con denominador⁸ muy chico en cada sumando, esto hará que la base⁹ de cada sumando sea un número negativo muy grande¹⁰, por lo que al elevar al cuadrado será un error enorme. Por otro lado, $f_{(a)}$ tiene un error más razonable. Conclusión, el modelo planteado en el inciso (a) se ajusta más a los datos.

⁷Ponele.

⁸ Numerador / Denominador.

⁹ Base / Exponente.

¹⁰ Muy grande en módulo.



Ejercicio 3

- (a) Probar que si A es real entonces $A^T A$ y AA^T tienen los mismos autovalores no nulos.
 (b) Probar que si A es real y cuadrada, $\|Ax\|_2 \geq \|x\|_2$ para todo x y $\max_{\|x\|_2=1} \|AA^T x\|_2 = 1$, entonces A es ortogonal.

Inciso (a)

Dos formas para demostrarlo. Sea $A \in \mathbb{R}^{m \times n}$.

Por definición

Queremos ver que existen $v \in \mathbb{R}^n$ y $w \in \mathbb{R}^m$ tales que para todo $\lambda \in \mathbb{R} \setminus \{0\}$, $A^T A v = \lambda v \iff AA^T w = \lambda w$.

$$A^T A v = \lambda v \implies AA^T(Av) = \lambda(Av) \implies AA^T w = \lambda w \quad Av = w \in \mathbb{R}^m$$

$$AA^T w = \lambda w \implies A^T A(A^T w) = \lambda(A^T w) \implies A^T A v = \lambda v \quad A^T w = v \in \mathbb{R}^n$$

Notar que podría relativizar esta demostración para $\mathbb{K}$ en lugar de $\mathbb{R}$.

Por descomposición en valores singulares

Sabemos que $A \in \mathbb{R}^{m \times n}$ se puede escribir como $A = U\Sigma V^T$, donde $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ son ortogonales y $\Sigma \in \mathbb{R}^{m \times n}$ es diagonal con los valores singulares de A en la misma.

Veamos cómo queda $A^T A$ y AA^T :

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T \stackrel{U^T U = I}{=} V\Sigma^T \Sigma V^T$$

$$AA^T = (U\Sigma V^T)(U\Sigma V^T)^T = U\Sigma V^T V\Sigma^T U^T \stackrel{V^T V = I}{=} U\Sigma \Sigma^T U^T$$

Separaremos en tres casos, $m = n$, $m > n$ y $m < n$.

Me saco de encima primero el caso fácil, $m = n$. Recordar que si D es diagonal cuadrada, $D^T = D$.

$$A^T A = V\Sigma^T \Sigma V^T = V\Sigma^2 V^T$$

$$AA^T = U\Sigma \Sigma^T U^T = U\Sigma^2 U^T$$

Luego, $A^T A, AA^T$ comparten autovalores pues tanto $A^T A$ como AA^T son semejantes a Σ^2 diagonal.

Veamos ahora los otros dos casos. Sea $r \leq \min(m, n)$ el rango de la matriz A .

Supongamos que $m > n$.

$$A^T A = V \begin{pmatrix} \sigma_1 & 0 & \dots & \dots & \dots & 0 & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 & \dots & 0 \\ \vdots & 0 & \sigma_r & 0 & \dots & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \dots & 0 \\ 0 & 0 & 0 & 0 & \dots & 0 & \dots & 0 \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} V^T = V \begin{pmatrix} \sigma_1^2 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r^2 & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \end{pmatrix} V^T$$

$$AA^T = U \begin{pmatrix} \sigma_1 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \end{pmatrix} U^T = U \begin{pmatrix} \sigma_1^2 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r^2 & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} U^T$$

Se puede observar claramente que ambas matrices son semejantes a una matriz diagonal similar, que contiene con los mismos autovalores no nulos, $\sigma_1^2, \dots, \sigma_r^2$, y por lo tanto comparten autovalores no nulos.

Ahora supongamos que $m < n$.

$$A^T A = V \begin{pmatrix} \sigma_1 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} V^T = V \begin{pmatrix} \sigma_1^2 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r^2 & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} V^T$$

$$A A^T = U \begin{pmatrix} \sigma_1 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} U^T = U \begin{pmatrix} \sigma_1^2 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & 0 & \dots & \dots & 0 \\ \vdots & 0 & \sigma_r^2 & 0 & \dots & 0 \\ \vdots & \vdots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} U^T$$

Igual que antes, se puede observar claramente que ambas matrices son semejantes a una matriz diagonal similar, que contiene con los mismos autovalores no nulos, $\sigma_1^2, \dots, \sigma_r^2$, y por lo tanto comparten autovalores no nulos.

Inciso (b)

Repasemos primero las definiciones de ortogonalidad que tenemos. Una matriz $Q \in \mathbb{R}^{n \times n}$ es ortogonal si:

- * $Q^T = Q^{-1}$.
 - * $Q Q^T = Q^T Q = I$.
 - * $\|Qx\|_2 = \|x\|_2$.
 - * Las cols de Q forman una base ortonormal de $\mathbb{R}^n$.
 - * Las filas de Q forman una base ortonormal de $\mathbb{R}^n$.
 - * Q se puede escribir como el producto de dos matrices ortogonales.
 - ↳ La Σ en la SVD de Q es la matriz identidad.
- No sé si es un $\iff$, pero seguro que esto implica que Q es ortogonal.

Creo que puede salir por la de que la Σ en la SVD de A es la identidad. Para este approach necesito que A sea de rango completo para que me quede la identidad en la Σ de la SVD.

Veamos primero entonces que A es de rango completo.

Supongamos que A no es de rango completo, es decir, $\text{rk}(A) = \dim(\text{Im}(A)) < n$, entonces, por el teorema de la dimensión¹¹, $\text{Nu}(A) > 0$. Esto implica que existe un vector $x_0 \neq 0 \in \mathbb{R}^n$ tal que $Ax_0 = 0$.

Luego, por hipótesis¹², tenemos que:

$$0 = \|0\|_2 = \|Ax_0\|_2 \geq \|x_0\|_2 > 0 \text{ pues } x_0 \neq 0$$

¡Absurdo!, por lo que $\text{Nu}(A) = \{0\}$

Esto implica que A es de rango completo, es decir, $\text{rk}(A) = \dim(\text{Im}(A)) = n$, o en términos de la demo, $r = n$.

Bien, ahora tenemos que ver que todos los valores singulares de A son iguales a 1.

Podemos buscar acotar con $1 \geq \sigma_1$ y $\sigma_r \geq 1$, donde σ_1 es el valor singular más grande de A y σ_r es el valor singular más chico de A . Busquemos ambas cotas por separado. Veamos la superior:

$$1 \stackrel{\text{hipótesis}^{13}}{=} \max_{\|x\|_2=1} \|AA^T x\|_2 \geq \max_{\|x\|_2=1} \|A^T x\|_2 \stackrel{\text{prop.}}{=} \sigma_1 \longleftarrow \text{mayor valor singular de } A^T$$

¹¹Si $A \in \mathbb{R}^{n \times n}$, entonces $\dim(\text{Im}(A)) + \dim(\text{Nu}(A)) = n$.

¹² $\|Ax\|_2 \geq \|x\|_2$.

¹³ $\max_{\|x\|_2=1} \|AA^T x\|_2 = 1$.

Recordar que A^T y A comparten valores singulares pues $A = U\Sigma V^T$ y $A^T = V\Sigma U^T$.

Esto quiere decir que, el valor singular más grande de A^T y A , que es σ_1 , es ≤ 1 .

Si logramos demostrar que el valor singular más chico de A , que es σ_r , es ≥ 1 , ganamos; pues ensanguchamos a todos tal que $1 \geq \sigma_1 \geq \dots \geq \sigma_r \geq 1$, lo que implica que $\sigma_i = 1$ para todo $1 \leq i \leq r$.

Como A es de rango completo, sabemos que $\min_{\|x\|_2=1} \|Ax\|_2 = \sigma_r$.

Luego, como $\|Ax\|_2 \geq \|x\|_2$ para todo x , tenemos que

$$\sigma_r \underset{\text{prop.}}{=} \min_{\|x\|_2=1} \|Ax\|_2 \underset{\text{hipótesis}^{12}}{\geq} \min_{\|x\|_2=1} \|x\|_2 = 1$$

Finalmente, $A = UIV^T = UV^T$ es ortogonal, pues U y V^T son ortogonales.

Ejercicio 4

Sea A una matriz cuadrada cuya diagonal es la identidad.

(a) Sea B_J la matriz asociada al método de Jacobi. Para cada $\omega > 0$ se define la relajación

$$B_\omega = \omega B_J + (1 - \omega)I.$$

Probar que $Ax = b$ si y solo si

$$x = B_\omega x + \omega b.$$

(b) Sea $A = \begin{pmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{pmatrix}$ y el método iterativo $x^{(k+1)} = B_\omega x^{(k)} + \omega b$.

(i) Dar los valores de ω para los cuales el método converge.

(ii) ¿Qué valores de ω aseguran que el método planteado converge más rápido que el de Jacobi?

Recordemos primero cómo es la matriz asociada al método de Jacobi. Separo $A = D + L + U$:

$$\begin{aligned} (D + L + U)x = b &\Leftrightarrow Dx + (L + U)x = b \\ &\Leftrightarrow Dx = -(L + U)x + b \\ &\Leftrightarrow x = \underbrace{-\underbrace{D^{-1}(L + U)}_{B_J} x}_{\underbrace{\quad}_{M}} + \underbrace{D^{-1}b}_M \end{aligned}$$

Sin embargo, para este ejercicio $D = I$, luego

$$\begin{aligned} B_J &= -D^{-1}(L + U) \\ &= -I^{-1}(L + U) \\ &= -I(L + U) \\ &= -(L + U) \end{aligned}$$

Inciso (a)

Vamos a ver como estoy de manejo algebraico porque este item es, hacer manipulaciones algebraicas.

$$\begin{aligned} x = B_\omega x + \omega b &\Leftrightarrow x = \underbrace{(\omega B_J + (1 - \omega)I)}_{B_\omega} x + \omega b \\ &\Leftrightarrow x = \left(\omega \underbrace{(-(L + U))}_{B_J} + (1 - \omega)I \right) x + \omega b \\ &\Leftrightarrow x = (-\omega(L + U) + (1 - \omega)I)x + \omega b \\ &\Leftrightarrow x = (-\omega(L + U) + I - \omega I)x + \omega b \\ &\Leftrightarrow x = (-\omega L - \omega U + I - \omega I)x + \omega b \\ &\Leftrightarrow x = -\omega Lx - \omega Ux + x - \omega Ix + \omega b \\ &\Leftrightarrow x = -\omega Ix - \omega Lx - \omega Ux + x + \omega b \\ &\Leftrightarrow \omega Ix + \omega Lx + \omega Ux + x - x = \omega b \\ &\Leftrightarrow \omega Ix + \omega Lx + \omega Ux = \omega b \\ &\Leftrightarrow \omega(I + L + U)x = \omega b \\ &\stackrel{\omega \neq 0}{\Leftrightarrow} (I + L + U)x = b \\ &\Leftrightarrow (D + L + U)x = b \\ &\Leftrightarrow Ax = b \end{aligned}$$

Inciso (b)

Sabemos que un método iterativo, con B la matriz asociada, converge si y solo si $\rho(B) < 1$, donde ρ es el radio espectral de la matriz.

Subinciso (i)

Busquemos el radio espectral de B_ω , y definamos qué valores de ω hacen que $\rho(B_\omega) < 1$.

Para ello, primero necesitamos calcular B_ω para la matriz $A = \begin{pmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{pmatrix}$:

$$\begin{aligned} B_\omega &= \omega B_J + (1 - \omega)I \\ &= \omega \underbrace{-(L + U)}_{B_J} + (1 - \omega)I \\ &= -\omega(L + U) + (1 - \omega)I \\ &= -\omega L - \omega U + I - \omega I \\ &= -\omega I - \omega L - \omega U + I \\ &= -\omega(I + L + U) + I \\ &= -\omega A + I \end{aligned}$$

Luego, para la matriz A dada:

$$B_\omega = -\omega \begin{pmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{pmatrix} + \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 - \omega & -\frac{\omega}{2} \\ -\frac{\omega}{2} & 1 - \omega \end{pmatrix}$$

Ahora, calculemos el radio espectral de B_ω .

Para ello busquemos los autovalores de B_ω , y nos quedamos con el más grande en módulo:

$$\begin{aligned} \lambda \text{ es autovalor de } B_\omega &\iff \det(B_\omega - \lambda I) = 0 \\ &\iff \begin{vmatrix} 1 - \omega - \lambda & -\frac{\omega}{2} \\ -\frac{\omega}{2} & 1 - \omega - \lambda \end{vmatrix} = 0 \\ &\iff (1 - \omega - \lambda)(1 - \omega - \lambda) - \left(-\frac{\omega}{2}\right)\left(-\frac{\omega}{2}\right) = 0 \\ &\iff (1 - \omega - \lambda)^2 - \frac{\omega^2}{4} = 0 \\ &\iff (1 - \omega - \lambda)^2 = \frac{\omega^2}{4} \\ &\iff 1 - \omega - \lambda = \pm \frac{\omega}{2} \\ &\iff \lambda = 1 - \omega \pm \frac{\omega}{2} \\ &\iff \lambda = 1 - \frac{\omega}{2} \vee \lambda = 1 - 3\frac{\omega}{2} \end{aligned}$$

Luego, tenemos que buscar ω tal que $\max(|1 - \frac{\omega}{2}|, |1 - 3\frac{\omega}{2}|) < 1$. Como a priori no sé cuál es el mayor, voy a analizar ambos casos, y luego ver cuál es el que me da la restricción más fuerte.

$$\begin{aligned} |1 - \frac{\omega}{2}| < 1 &\iff -1 < 1 - \frac{\omega}{2} < 1 \\ &\iff -2 < -\frac{\omega}{2} < 0 \\ &\iff -4 < -\omega < 0 \\ &\iff 0 < \omega < 4 \\ |1 - 3\frac{\omega}{2}| < 1 &\iff -1 < 1 - 3\frac{\omega}{2} < 1 \\ &\iff -2 < -3\frac{\omega}{2} < 0 \\ &\iff -\frac{4}{3} < -\omega < 0 \\ &\iff 0 < \omega < \frac{4}{3} \end{aligned}$$

Luego, la restricción más fuerte es $0 < \omega < \frac{4}{3}$.

Por lo que para que el método converja, necesitamos que ω esté en el intervalo $(0, \frac{4}{3})$.

Subinciso (ii)

Sabemos que mientras más chico el radio espectral, más rápido converge el método.

Para compararlo con el de Jacobi necesitamos calcular el radio espectral de B_J , y así, ver qué valores de ω hacen que $\rho(B_\omega) < \rho(B_J)$.

$$A = \begin{pmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}_D + \underbrace{\begin{pmatrix} 0 & 0 \\ \frac{1}{2} & 0 \end{pmatrix}}_L + \underbrace{\begin{pmatrix} 0 & \frac{1}{2} \\ 0 & 0 \end{pmatrix}}_U$$

Luego,

$$B_J = -(L + U) = \begin{pmatrix} 0 & -\frac{1}{2} \\ -\frac{1}{2} & 0 \end{pmatrix}$$

Calculemos el radio espectral de B_J :

$$\begin{aligned} \lambda \text{ es autovalor de } B_J &\iff \det(B_J - \lambda I) = 0 \\ &\iff \begin{vmatrix} -\lambda & -\frac{1}{2} \\ -\frac{1}{2} & -\lambda \end{vmatrix} = 0 \\ &\iff (-\lambda)(-\lambda) - \left(-\frac{1}{2}\right)\left(-\frac{1}{2}\right) = 0 \\ &\iff \lambda^2 - \frac{1}{4} = 0 \\ &\iff \lambda^2 = \frac{1}{4} \\ &\iff \lambda = \pm \frac{1}{2} \end{aligned}$$

Luego, el radio espectral de B_J es $\rho(B_J) = \frac{1}{2}$.

Ahora, busquemos los valores de ω tales que $\rho(B_\omega) < \frac{1}{2}$:

$$\begin{aligned} |1 - \frac{\omega}{2}| < \frac{1}{2} &\iff -\frac{1}{2} < 1 - \frac{\omega}{2} < \frac{1}{2} \\ &\iff -\frac{3}{2} < -\frac{\omega}{2} < -\frac{1}{2} \\ &\iff -3 < -\omega < -1 \\ &\iff 1 < \omega < 3 \\ |1 - 3\frac{\omega}{2}| < \frac{1}{2} &\iff -\frac{1}{2} < 1 - 3\frac{\omega}{2} < \frac{1}{2} \\ &\iff -\frac{3}{2} < -3\frac{\omega}{2} < -\frac{1}{2} \\ &\iff -3 < -3\omega < -1 \\ &\iff -1 < -\omega < -\frac{1}{3} \\ &\iff \frac{1}{3} < \omega < 1 \end{aligned}$$

¿Qué pasó?, bueno, acá hay que saber interpretar los resultados.

Supongamos que $\lambda = 1 - \frac{\omega}{2}$ era el autovalor mayor en módulo, entonces si tomamos un ω en el intervalo $(1, 3)$, tenemos que $\frac{1}{2} > |1 - \frac{\omega}{2}|$, y como $1 - \frac{\omega}{2}$ es el autovalor mayor en módulo, $|1 - \frac{\omega}{2}| \geq |1 - 3\frac{\omega}{2}|$, pero notemos que esto último no es cierto pues si tomamos un ω en el intervalo $(1, 3)$ que no comparte nada con el $(\frac{1}{3}, 1)$, tenemos que $|1 - 3\frac{\omega}{2}| \geq \frac{1}{2}$, por lo que nos queda $\frac{1}{2} > |1 - \frac{\omega}{2}| \geq |1 - 3\frac{\omega}{2}| \geq \frac{1}{2}$, lo que implica que $\frac{1}{2} > \frac{1}{2}$ que es absurdo.

Ahora, supongamos el otro caso, que $\lambda = 1 - 3\frac{\omega}{2}$ es el autovalor mayor en módulo, entonces si tomamos un ω en el intervalo $(\frac{1}{3}, 1)$, tenemos que $\frac{1}{2} > |1 - 3\frac{\omega}{2}|$, y como $1 - 3\frac{\omega}{2}$ es el autovalor mayor en módulo, $|1 - 3\frac{\omega}{2}| \geq |1 - \frac{\omega}{2}|$, pero notemos que esto último no es cierto pues si tomamos un ω en el intervalo $(\frac{1}{3}, 1)$ que no comparte nada

con el $(1, 3)$, tenemos que $|1 - \frac{\omega}{2}| \geq \frac{1}{2}$, por lo que nos queda $\frac{1}{2} > |1 - 3\frac{\omega}{2}| \geq |1 - \frac{\omega}{2}| \geq \frac{1}{2}$, lo que implica que $\frac{1}{2} > \frac{1}{2}$ que es absurdo.

Concluyendo, no hay valores de ω que hagan que el método converja más rápido que el de Jacobi.